Выбор кластеризации при малой разметке

Идея: подключать геометрию, когда оценки по меткам близки с учётом их разброса

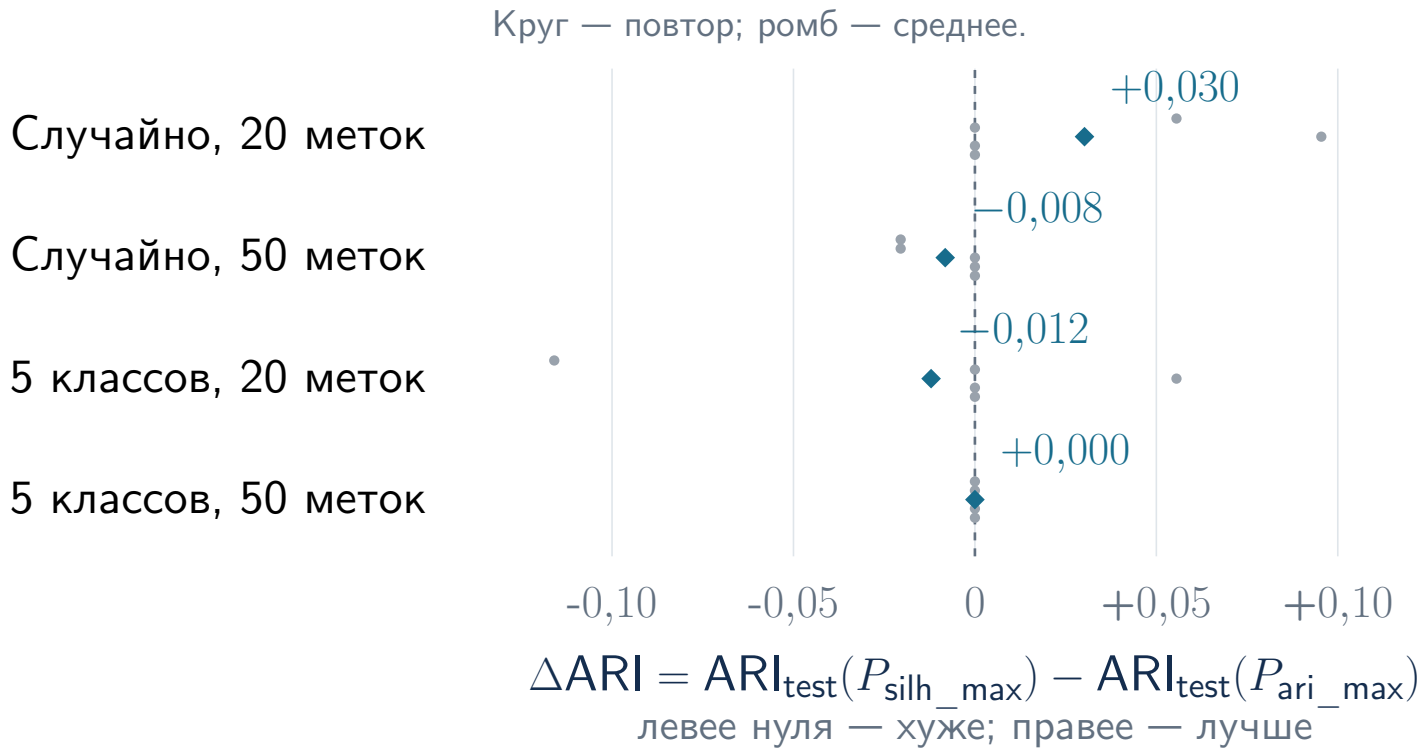

Разбиения

$P_{\text{ari_max}}$: максимум ARI на доступных метках.

$P_{\text{silh_max}}$: максимум silhouette среди близких по ARI вариантов.

Допуск — по бутстреп-ному разбросу разности ARI.

20 случайных меток: $+0{,}030$ ARI При 50 метках: $-0{,}008$

Вопрос работы: когда геометрия помогает и как это зависит от покрытия классов?

Пилот Digits: 600 объектов, 10 классов, 8 готовых разбиений; ARI на 300 скрытых проверочных метках.

5 повторений разметки на условие, 30 бутстрепов.